



# Topic Modeling

Rabu, 3 Januari 2024

- Satria Bagus Panuntun

# Isi


- Konsep topic modeling
- Tujuan topic modeling
- LDA
- Tahapan-tahapan topic modeling
- Praktik preprocessing

# Konsep Dasar



# Apa itu topic modeling?

Topic modeling merupakan salah satu pendekatan pada Text Mining yang cukup handal dalam melakukan penemuan data-data teks yang tersembunyi dan menemukan hubungan antara teks yang satu dengan lainnya dari suatu corpus (Jelodar, et al., 2018).



# Apa itu topic modeling?

- Topic modeling adalah jenis model statistik untuk menemukan "topik" abstrak yang terdapat dalam kumpulan dokumen [1]
- Topic modeling adalah serangkaian algoritma yang mengungkap struktur tematik tersembunyi dalam koleksi dokumen. Algoritma ini membantu mengembangkan cara baru untuk mencari, menelusuri, dan meringkas arsip teks berukuran besar [2]
- Topik modeling menyediakan cara sederhana untuk menganalisis teks tak berlabel dalam jumlah besar. Sebuah "topik" terdiri dari sekelompok kata yang sering muncul bersamaan[3]

# Apa itu topic modeling?

Mengelompokkan data teks berdasarkan suatu topik tertentu. Cara kerja topik modelling seperti clustering, dikatakan seperti clustering karena mengelompokkan dokumen berdasarkan kemiripannya. Topic Modelling termasuk unsupervised learning karena data yang digunakan tidak memiliki label.

Salah satu metode Topic Modeling adalah dengan menggunakan metode **Latent Dirichlet Allocation (LDA)**

# Tujuan Topic Modeling



# Mengidentifikasi Pola dalam Data Teks

- Menemukan topik tersembunyi dalam kumpulan dokumen besar.
- Contoh penelitian:
  1. Analisis tren topik dalam artikel berita selama satu dekade.
  2. Studi tentang topik yang sering dibahas dalam forum online.

# Mengelompokkan Dokumen Berdasarkan Topik

- Mengelompokkan dokumen yang memiliki kesamaan topik.
- Contoh penelitian:
  1. Pengelompokan ulasan produk untuk analisis sentimen.
  2. Klasifikasi artikel jurnal berdasarkan bidang penelitian.

# Menyederhanakan Data Teks untuk Analisis Lebih Lanjut

- Mengurangi dimensi data teks untuk memudahkan analisis.
- Contoh penelitian:
  1. Penggunaan topic modeling untuk menyederhanakan data teks sebelum analisis machine learning.
  2. Penerapan dalam analisis data besar untuk efisiensi.

# Membantu dalam Rekomendasi Konten

- Menyediakan rekomendasi konten yang relevan berdasarkan topik yang diminati pengguna.
- Contoh penelitian:
  1. Sistem rekomendasi artikel berdasarkan topik yang sering dibaca pengguna.
  2. Rekomendasi film atau buku berdasarkan preferensi topik.

LDA




# Latent Dirichlet Allocation (LDA)

LDA pertama kali diperkenalkan oleh Blei, Ng dan Jordan pada tahun 2003, adalah salah satu metode paling populer dalam pemodelan topik.

Putra & Kusumawardani (2017) mengatakan bahwa LDA dapat digunakan untuk meringkas, melakukan klasterisasi, menghubungkan maupun memproses data yang sangat besar karena LDA menghasilkan daftar topik yang diberi bobot untuk masing-masing dokumen.

# Latent Dirichlet Allocation (LDA)



## Komponen Utama:

- Dokumen (M): Kumpulan teks yang dianalisis.
- Kata (N): Kata-kata dalam dokumen.
- Topik (K): Kumpulan kata yang sering muncul bersama dalam dokumen.

## Parameter Penting:

- $\alpha$  (alpha): Parameter konsentrasi untuk distribusi topik per dokumen.
- $\beta$  (beta): Parameter konsentrasi untuk distribusi kata per topik.
- $\psi$  (psi): Distribusi topik untuk dokumen tertentu.
- $\phi$  (phi): Distribusi kata untuk topik tertentu.

# Kelebihan dan Kekurangan LDA

## Kelebihan:

- Mampu menangani data teks besar.
- Menghasilkan interpretasi yang mudah dipahami dari data yang kompleks.
- Fleksibel dalam berbagai aplikasi, seperti analisis sentimen dan pengelompokan dokumen.


## Kekurangan:

- Memerlukan pemilihan jumlah topik yang tepat.
- Sensitif terhadap parameter awal dan dapat terjebak dalam solusi lokal.
- Tidak mempertimbangkan urutan kata dalam dokumen.

# Tahapan Topic Modeling



# Tahapan topic modeling



# Preprocessing

## Preprocessing

### Tokenization

#### Simple

transition, metal, oxides,  
considered, generation,  
materials, field, electronics,  
advanced, catalysts, tantalum,  
v, oxide, reports, synthesis,  
material, nanometer, size,  
unusual, properties...

#### Collocations

transition\_metal\_oxides,  
considered, generation,  
materials, field, electronics,  
advanced, catalysts, tantalum,  
oxide, reports, synthesis,  
material, nanometer\_size,  
unusual, properties,  
sol\_gel\_method,  
biomedical\_applications...

#### Entities

transition, metal\_oxides,  
tantalum, oxide,  
nanometer\_size,  
unusual\_properties, dna,  
easy\_method,  
biomedical\_applications

#### language

generic

a  
above  
across  
after  
afterwards  
again  
against  
all  
...

#### domain

specific

material  
temperature  
advance  
size  
....

#### Combination

transition, metal\_oxides,  
generation, tantalum, oxide,  
nanometer\_size,  
unusual\_properties, sol, dna,  
easy\_method,  
biomedical\_applications

#### Lemmatization

transition, metal, oxide,  
consider, generation, material,  
field, electronic, advance,  
catalyst, property...

# Preprocessing

## Pertanyaan

Jajanan Pasar yang murah meriah dimana sih?  
oleh-oleh jogja apa aja?  
makan cupcake yang enak dimana ya?  
Yg jual lemper di jogja mana ya?  
Makanan ringan khas yogyakarta dimana??  
Dimana yang menjual jajanan hits yang enak dan murah?  
jual kue ulang tahun dimana?  
Bakpia enak di jogja  
Lokasi penjual jajanan oleh asli khas jogjakarta  
Dimana lokasi menjual kue coklat lumer  
kue artis di jogja apa aja?  
makanan yang unik dan enak dimna sih? jual kue pancong dimna ? jual kembang tahu dimana saja ?  
Toko Bakeries dimana ya?  
makanan untuk oleh-oleh apa ya?  
Tempat nongkrong yang asik dimana?  
Tempat nongkrong yang harganya terjangkau dimana sih ?  
Signature dish di kopi klotok apa ya ?  
Tempat makan yg enak buat tugas dan ada wifi deket jakal dimana ya?



1	text	
2	jajanan pasar murah meriah	
3		
4	makan cupcake enak	
5	lemper	
6	ringan khas	
7	jajanan hits enak murah	
8	kue ulang tahun	
9	bakpia enak	
10	lokasi penjual jajanan asli khas jogjakarta	
11	lokasi kue coklat lumer	
12	kue artis	

# Vector Space

## Vector Space

### Dictionary

- 1 - transition
- 2- metal
- 3- oxides
- 4- considered
- ...

### Corpus - Bag of words

```
[(0, 1), (1, 1), (2, 1)]  
[(0, 1), (3, 1), (4, 1), (5, 1), (6, 1), (7, 1)]  
[(2, 1), (5, 1), (7, 1), (8, 1)]  
[(1, 1), (5, 2), (8, 1)]  
[(3, 1), (6, 1), (7, 1)]  
[(9, 1)]  
[(9, 1), (10, 1)]  
[(9, 1), (10, 1), (11, 1)]  
[(4, 1), (10, 1), (11, 1)]
```

# Vector Space

tweet\_clean



selamat malam sobat industri kabar nih ekonomi nasional

alhamdulillah

emang top deh era presiden ri catat jaran nkri tumbuh ekonomi trwulan ii pandemi ekonomi tumbuh lejit

terimakasih obrol mas saran kritik makna upaya tingkat potensi sektor tani ekonomi indonesia

$[(0, 1), (1, 1), (2, 1), (3, 1), (4, 1)]$

$(5, 1)$

$[(6, 1), (7, 1), (8, 1), (9, 1), (10, 1), (11, 1), (12, 1), (13, 1), (14, 1), (15, 1)]$


$[(16, 1), (17, 1), (18, 1), (19, 1), (20, 1), (21, 1)]$

# Gensim Model

## Gensim Models

- [`models.ldamodel` – Latent Dirichlet Allocation](#)
- [`models.ldamulticore` – parallelized Latent Dirichlet Allocation](#)
- [`models.lsimodel` – Latent Semantic Indexing](#)
- [`models.tfidfmodel` – TF-IDF model](#)
- [`models.rpmodel` – Random Projections](#)
- [`models.hdpmodel` – Hierarchical Dirichlet Process](#)
- [`models.logentropy\_model` – LogEntropy model](#)
- [`models.lsi\_dispatcher` – Dispatcher for distributed LSI](#)
- [`models.lsi\_worker` – Worker for distributed LSI](#)
- [`models.lda\_dispatcher` – Dispatcher for distributed LDA](#)
- [`models.lda\_worker` – Worker for distributed LDA](#)
- [`models.word2vec` – Deep learning with word2vec](#)
- [`models.doc2vec` – Deep learning with paragraph2vec](#)
- [`models.phrases` – Phrase \(collocation\) detection](#)
- [`models.wrappers.ldamallet` – Latent Dirichlet Allocation via Mallet](#)
- [`models.wrappers.dtmmodel` – Dynamic Topic Models \(DTM\) and Dynamic Influence Models \(DIM\)](#)
- [`models.wrappers.ldavowpalwabbit` – Latent Dirichlet Allocation via Vowpal Wabbit](#)

# Evaluasi



## Evaluasi (Interpretasi)

```
Topic: 0 Word: 0.103*"makan" + 0.075*"halal" + 0.063*"pedas" + 0.053  
*"korea" + 0.052*"lokasi" + 0.045*"murah" + 0.036*"lokasinya" + 0.034  
*"menu" + 0.031*"cafe" + 0.027*"nyaman"  
Topic: 1 Word: 0.153*"murah" + 0.116*"lokasi" + 0.069*"harga" + 0.064  
*"seafood" + 0.048*"makan" + 0.039*"mahasiswa" + 0.029*"kantong" + 0.0  
28*"terkenal" + 0.025*"terjangkau" + 0.025*"terenak"  
Topic: 2 Word: 0.149*"khas" + 0.054*"masakan" + 0.052*"lokasi" + 0.046  
*"promo" + 0.043*"wisata" + 0.041*"makan" + 0.034*"ayam" + 0.034*"nong  
krong" + 0.032*"terdekat" + 0.029*"warung"
```

Ini berarti 10 kata kunci teratas yang berkontribusi pada topik 0 adalah: 'makan', 'pedas', 'halal', 'korea' .. dan seterusnya dan bobot 'halal' pada topik 0 adalah 0,075. Bobot mencerminkan betapa pentingnya kata kunci untuk topik itu.

## Evaluasi (Interpretasi)

```
Topic: 0 Word: 0.103*"makan" + 0.075*"halal" + 0.063*"pedas" + 0.053  
*"korea" + 0.052*"lokasi" + 0.045*"murah" + 0.036*"lokasinya" + 0.034  
*"menu" + 0.031*"cafe" + 0.027*"nyaman"  
Topic: 1 Word: 0.153*"murah" + 0.116*"lokasi" + 0.069*"harga" + 0.064  
*"seafood" + 0.048*"makan" + 0.039*"mahasiswa" + 0.029*"kantong" + 0.0  
28*"terkenal" + 0.025*"terjangkau" + 0.025*"terenak"  
Topic: 2 Word: 0.149*"khas" + 0.054*"masakan" + 0.052*"lokasi" + 0.046  
*"promo" + 0.043*"wisata" + 0.041*"makan" + 0.034*"ayam" + 0.034*"nong  
krong" + 0.032*"terdekat" + 0.029*"warung"
```

Topik 0 memiliki model dengan pembahasan masakan Korea, halal, memiliki rasa pedas. Tidak hanya itu, topik ini juga membahas cafe yang nyaman, bagus, serta kekinian. Maka kelompok topik 2 isinya yaitu tentang kuliner/masakan luar negeri yang memiliki sertifikat halal di Yogyakarta.

# Praktik Topic Modeling





## Install Library NLTK



Natural Language Toolkit atau disingkat NLTK, adalah library python untuk bekerja dengan bahasa manusia. Tujuan utamanya adalah mempersiapkan teks sebelum digunakan pada machine learning atau algoritma deep learning.



5s

```
[1] pip install nltk
```

```
Requirement already satisfied: nltk in /usr/local/lib/python3.10/dist-packages
Requirement already satisfied: click in /usr/local/lib/python3.10/dist-packages
Requirement already satisfied: joblib in /usr/local/lib/python3.10/dist-packages
Requirement already satisfied: regex>=2021.8.3 in /usr/local/lib/python3.10/dist-packages
Requirement already satisfied: tqdm in /usr/local/lib/python3.10/dist-packages
```

## Install Library Sastrawi

Python Sastrawi adalah pengembangan dari proyek PHP Sastrawi. Python Sastrawi merupakan perpustakaan yang memudahkan pengembang untuk memproses berimbahan bahasa Indonesia menjadi bentuk dasarnya.

## Link colab:

<https://drive.google.com/drive/folders/13aQgM07VBb8Fafnz4GDC1AFzCvi9ETjd?hl=id>